Machine Learning on VLSI

Proyecto Final

Alumno:

Manuel Exequiel Arias

8 de mayo de 2026

Índice

1. Enunciado del proyecto **3**
1.1. Objetivo . . . 3
1.2. Dataset . . . 3
1.3. Problema a resolver . . . 3
1.4. Desarrollo del modelo . . . 3
1.5. Cuantización del modelo . . . 4
1.6. Análisis para implementación en hardware . . . 4
1.7. Resultados esperados . . . 5

2. Desarrollo **6**
2.1. Análisis y Preprocesamiento del Dataset . . . 6
2.1.1. Estructura de Datos . . . 6
2.1.2. Partición del Conjunto de Datos . . . 6
2.1.3. Codificación de Etiquetas . . . 6
2.1.4. Normalización de Amplitud . . . 7
2.2. Desarrollo y Entrenamiento del Modelo . . . 7
2.2.1. Diseño de la Arquitectura de la Red Neuronal . . . 7
2.2.2. Estrategia de Entrenamiento . . . 8
2.2.3. Evaluación y Métricas de Desempeño . . . 9
2.3. Cuantización del Modelo . . . 10
2.3.1. Análisis Estadístico de la Distribución de Parámetros . . . 10
2.3.2. Definición del Formato de Punto Fijo . . . 11
2.3.3. Transferencia de Pesos y Entrenamiento Consciente de Cuantización (QAT) . . . 12
2.3.4. Evaluación Comparativa de Rendimiento . . . 12
2.4. Análisis para Implementación en Hardware . . . 14
2.4.1. Estimación Energética mediante QTools . . . 14
2.4.2. Perfilado de Operaciones y Huella de Memoria . . . 14
2.4.3. Métricas Globales y Medida de Desempeño (Figure of Merit) 14
2.5. Resultados y Discusión: Impacto de la Cuantización . . . 15
2.5.1. Impacto sobre la Precisión (Accuracy vs. SNR) . . . 15
2.5.2. Impacto sobre la Estimación de Energía y Eficiencia . . . 16

1. Enunciado del proyecto

1.1. Objetivo

El objetivo del proyecto es diseñar, entrenar y analizar una red neuronal para resolver un problema de clasificación utilizando datos reales de señales de comunicaciones. Posteriormente, el modelo deberá optimizarse mediante técnicas de cuantización para evaluar su impacto en precisión, complejidad computacional y estimación de consumo energético.
El proyecto busca comprender el compromiso entre precisión del modelo y eficiencia de hardware, concepto central en el diseño de sistemas de inteligencia artificial para dispositivos de recursos limitados.

1.2. Dataset

El dataset utilizado es el RadioML 2016.10A, que contiene señales de radio simuladas representadas mediante muestras I/Q correspondientes a diferentes tipos de modulación y niveles de SNR (Signal-to-Noise Ratio).
Cada muestra contiene:

- 128 muestras complejas (I/Q)
- diferentes niveles de SNR
- distintos tipos de modulación

Cada ejemplo del dataset tiene dimensión: 2 x 128, donde la primera fila corresponde a la componente I y la segunda a la componente Q.

1.3. Problema a resolver

Se plantea un problema de clasificación supervisada.

- Entrada del modelo: Señal I/Q (2 x 128)
- Salida del modelo: Tipo de modulación de la señal.

El modelo deberá aprender a identificar automáticamente la modulación incluso en presencia de ruido.

1.4. Desarrollo del modelo

Tareas a realizar:

1. Analizar el dataset.
2. Preprocesar los datos.

3. Diseñar una red neuronal para el problema planteado y teniendo en cuenta la posterior implementación.
4. Entrenar el modelo utilizando TensorFlow / Keras.

El modelo podrá ser por ejemplo:

- Red totalmente conectada (MLP)
- CNN 1D
- CNN 2D

Se deberán evaluar métricas como:

- Accuracy
- Matriz de confusión
- Desempeño en función del SNR

1.5. Cuantización del modelo

Una vez entrenado el modelo en punto flotante, se deberá aplicar cuantización utilizando QKeras. Antes de definir el ancho de bits, se deberá realizar un análisis de la distribución de datos y pesos, con el fin de elegir de forma adecuada el rango de cuantización. El objetivo es analizar el impacto del ancho de bits en:

- precisión del modelo
- tamaño del modelo
- estimación de consumo energético.

1.6. Análisis para implementación en hardware

Utilizando herramientas de análisis de QKeras / QTools, se deberá estimar:

- número de operaciones MAC
- tamaño del modelo
- número de accesos a memoria
- estimación de consumo energético

Se deberá comparar el modelo original y el modelo cuantizado.

1.7. Resultados esperados

Se deberán comparar diferentes versiones del modelo:

- Modelo en punto flotante
- Modelo cuantizado (distintos bitwidth)

Se deberá analizar el impacto de la cuantización sobre:

- precisión
- tamaño del modelo
- estimación de energía

2. Desarrollo

2.1. Análisis y Preprocesamiento del Dataset

2.1.1. Estructura de Datos

El conjunto de datos RadioML 2016.10A se presenta originalmente estructurado mediante un diccionario, cuyas claves son tuplas que indican el tipo de modulación y la Relación Señal a Ruido (SNR) expresada en decibeles (dB). Para cada una de estas combinaciones, el dataset provee un conjunto de señales, donde cada muestra individual está representada por una matriz de dimensión 2×128. Estas dos filas corresponden a los canales In-Phase (Canal I o En Fase) y Quadrature (Canal Q o Cuadratura) de la señal de radiofrecuencia, mientras que las 128 columnas representan las muestras discretas en el dominio del tiempo.
A continuación, se grafica una señal de ejemplo donde se ven ambas componentes I y Q:

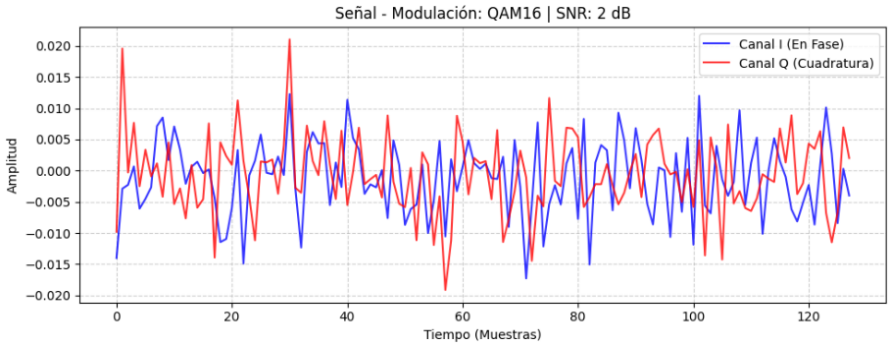

Figura 2.1: Ejemplo de señal I/Q del dataset RadioML 2016.10A (Modulación = QAM16, SNR = 2 dB).

2.1.2. Partición del Conjunto de Datos

Con el objetivo de evaluar la capacidad de generalización del modelo, los datos se dividieron en dos subconjuntos: uno de entrenamiento (`train`) y otro de prueba (`test`). Se adoptó una proporción del 80 % para el entrenamiento y el 20 % restante para la evaluación final.

2.1.3. Codificación de Etiquetas

Dado que las redes neuronales operan exclusivamente con valores numéricos, las etiquetas de modulación originales (presentadas como cadenas de texto, por ejemplo, `'QPSK'` o `'AM-DSB'`) fueron transformadas a formato entero. La lista quedó codificada de la siguiente manera:

- 0 → `'8PSK'`

- 1 → `'AM-DSB'`
- 2 → `'AM-SSB'`
- 3 → `'BPSK'`
- 4 → `'CPFSK'`
- 5 → `'GFSK'`
- 6 → `'PAM4'`
- 7 → `'QAM16'`
- 8 → `'QAM64'`
- 9 → `'QPSK'`
- 10 → `'WBFM'`

2.1.4. Normalización de Amplitud

Para optimizar la convergencia de los algoritmos de optimización durante el entrenamiento (como Adam) y evitar inestabilidades numéricas, se aplicó un proceso de normalización independiente a cada señal. Se identificó el valor absoluto máximo presente en cada matriz de 2×128 y se dividió la totalidad de la señal por dicho escalar. Este procedimiento escala las amplitudes de los canales I y Q al intervalo $[-1, 1]$. En las siguientes figuras se muestra la señal antes y después de normalizar, respectivamente:

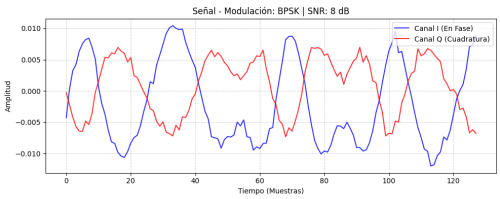

(a) Sin normalización

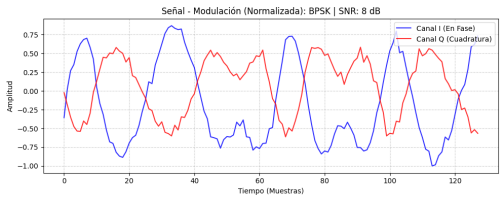

(b) Con normalización

Figura 2.2: Comparación de señales I/Q antes y después de la normalización.

2.2. Desarrollo y Entrenamiento del Modelo

2.2.1. Diseño de la Arquitectura de la Red Neuronal

Para resolver el problema de clasificación de las señales I/Q representadas en matrices de 2×128, se diseñó una red neuronal convolucional unidimensional (CNN 1D) con arquitectura residual (ResNet). Las arquitecturas residuales se caracterizan por la introducción de conexiones de salto que permiten que la entrada de un

bloque se sume directamente a su salida. Esta estructura facilita el entrenamiento de redes profundas al evitar el desvanecimiento del gradiente.
Una alternativa habría sido emplear una red totalmente conectada (MLP) a partir de la vectorización de cada muestra 2×128 en un solo vector de 256 entradas. Sin embargo, esa estrategia habría ignorado la correlación temporal entre muestras adyacentes y habría incrementado drásticamente el número de parámetros en las capas densas. En contraste, la CNN 1D captura la dependencia temporal de la señal, comparte pesos a lo largo del eje de tiempo y reduce el costo de operaciones MAC, lo que resulta más adecuado para un objetivo de implementación en hardware.
Inicialmente, los datos de entrada atraviesan una capa de permutación geométrica que reordena las dimensiones de $(2, 128)$ a $(128, 2)$, adecuando el tensor para el procesamiento temporal multicanal en Keras. A continuación, la arquitectura se estructura de la siguiente manera:

- **Capa Convolucional Inicial:** Expande el espacio de características utilizando 64 filtros con un tamaño de kernel de 7, seguido de normalización por lotes (*Batch Normalization*) y activación ReLU, estabilizando las varianzas complejas del espectro de radiofrecuencia.

- **Bloques Residuales:** Se implementaron dos bloques residuales secuenciales. El primer bloque opera con 64 filtros, mientras que el segundo aumenta la profundidad a 128 filtros para capturar patrones de alto nivel. Las conexiones residuales, implementadas mediante capas de suma, mitigan el problema del desvanecimiento del gradiente durante el entrenamiento y permiten un flujo de información más directo.

- **Clasificador Liviano:** En contraposición a las arquitecturas clásicas que utilizan capas de aplanamiento (*Flatten*), se incorporó una capa de Agrupamiento Promedio Global (*GlobalAveragePooling1D*). Esta decisión de diseño es crítica para la implementación en sistemas VLSI, ya que reduce drásticamente el número total de parámetros (pesos) y la cantidad de operaciones de multiplicación y acumulación (MAC), sin degradar significativamente la exactitud (*accuracy*) del modelo.

- **Regularización y Salida:** Se aplicó una capa de *Dropout* con una tasa del 50 % para penalizar el sobreajuste (*overfitting*) provocado por el ruido presente en cada señal. Finalmente, una capa densa con función de activación *Softmax* entrega la distribución de probabilidad sobre las 11 clases de modulaciones posibles.

2.2.2. Estrategia de Entrenamiento

El modelo en punto flotante fue entrenado utilizando el optimizador Adam, partiendo con una tasa de aprendizaje (*learning rate*) inicial de 0,01. Se empleó

la función de pérdida de entropía cruzada categórica dispersa (*Sparse Categorical Crossentropy*), adecuada para etiquetas enteras.

Para optimizar la convergencia, se integraron dos algoritmos de control (*callbacks*):

1. **Planificación Adaptativa (*ReduceLROnPlateau*):** Configurado para reducir la tasa de aprendizaje a la mitad si la pérdida de validación no mejora durante 2 épocas consecutivas, permitiendo un ajuste fino en las etapas finales del entrenamiento.

2. **Parada Temprana (*EarlyStopping*):** Diseñado para detener el entrenamiento tras 5 épocas sin mejoras en el conjunto de validación (fijado en un 20 % de los datos), restaurando automáticamente los pesos de la mejor época para asegurar una capacidad óptima de generalización.

El entrenamiento se configuró para un máximo de 30 épocas utilizando lotes (*batches*) de 32 muestras.

2.2.3. Evaluación y Métricas de Desempeño

Tras el entrenamiento, el modelo fue sometido a un análisis predictivo sobre el subconjunto de prueba. La evaluación global arrojó métricas de *accuracy* satisfactorias, considerando la severidad del ruido en la mitad del espectro del dataset.

Para aislar el desempeño de la red de la degradación absoluta de la señal, se analizó una **Matriz de Confusión** filtrada específicamente para señales con una SNR de -10, 0 y +10 dB. Este análisis permitió observar las confusiones intrínsecas del modelo entre modulaciones analógicamente similares (por ejemplo, entre WBFM y AM-DSB, o entre QAM16 y QAM64) sin la contaminación del ruido blanco excesivo. Se muestran las imágenes a continuación:

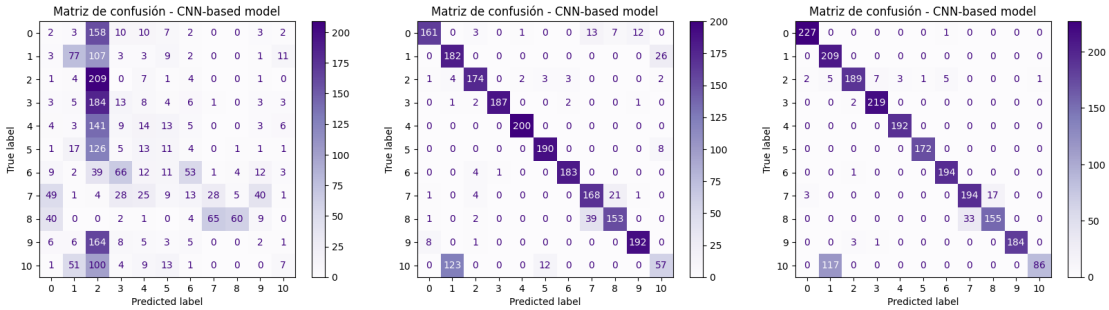

(a) SNR = -10 dB (b) SNR = 0 dB (c) SNR = +10 dB

Figura 2.3: Matriz de Confusión para diferentes niveles de SNR.

Finalmente, se trazó una **Curva de Precisión en función del SNR**. El gráfico evidencia el límite teórico del sistema: para SNRs inferiores a 0 dB, el modelo tiende a una precisión aleatoria ($\approx 9\,\%$), dado que las señales se encuentran

enmascaradas por el ruido. Sin embargo, a medida que la relación señal a ruido cruza el umbral de los 0 dB a +5 dB, la precisión del modelo experimenta un crecimiento asintótico, estabilizándose en sus valores máximos de *accuracy* para los registros más limpios del dataset.

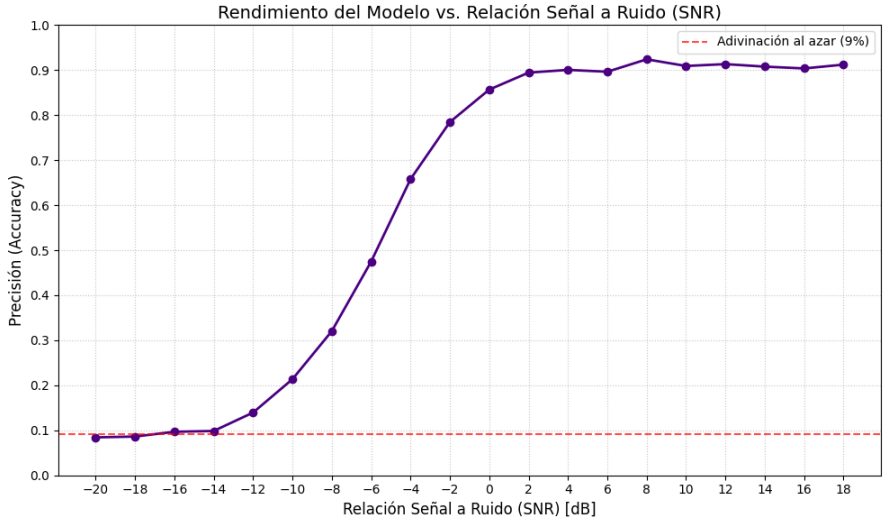

Figura 2.4: Curva de Precisión en función del SNR.

2.3. Cuantización del Modelo

2.3.1. Análisis Estadístico de la Distribución de Parámetros

El proceso de cuantización transforma la representación aritmética de los parámetros de punto flotante de 32 bits a aritmética de punto fijo, reduciendo significativamente el consumo de memoria y la complejidad lógica de los bloques multiplicadores-acumuladores (MAC). Para evitar severos errores de truncamiento (*clipping*) o pérdida de resolución fraccionaria, se realizó un análisis estadístico previo de los pesos (*kernels*) y sesgos (*biases*) extraídos del modelo base convergido.

El análisis de los histogramas reveló comportamientos marcadamente asimétricos entre los distintos tensores. Los *kernels* de las capas convolucionales y de la capa densa exhibieron distribuciones de tipo normal con colas extendidas, alcanzando valores cercanos a ± 16. Por el contrario, los sesgos de las operaciones convolucionales mostraron una varianza mínima, concentrándose en el rango $[-1, 1]$, mientras que el sesgo de la capa de salida presentó picos que superaban ligeramente este límite unitario.

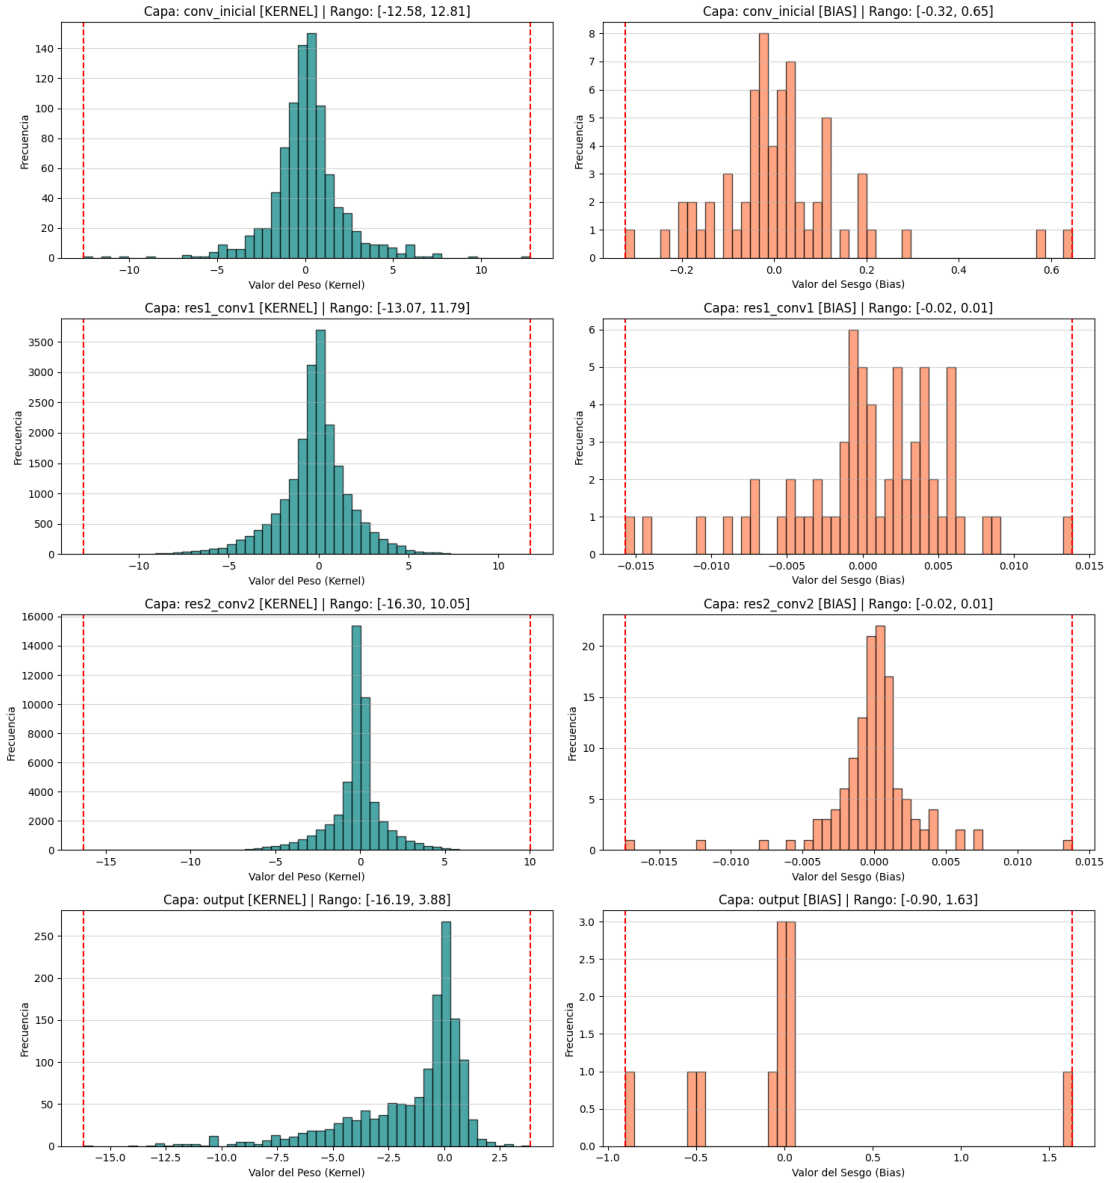

Figura 2.5: Histograma de pesos (kernels) y sesgos (biases).

Figura 2.6: Análisis estadístico de la distribución de pesos y sesgos del modelo base.

2.3.2. Definición del Formato de Punto Fijo

Con base en el análisis analítico de los rangos dinámicos, se configuraron estrategias de cuantización utilizando QKeras. Se fijó un ancho de palabra global de 8 bits para asegurar la viabilidad y eficiencia de la implementación física (VLSI), distribuyendo la posición de la coma de la siguiente manera:

- **Pesos (Kernels):** Se implementó el formato `quantized_bits(8, 4, 1)`,

reservando 4 bits enteros (más 1 bit de signo) para abarcar el rango dinámico exigido por las colas de la distribución de pesos, minimizando el error por saturación.

- **Sesgos Convolucionales (Biases):** Al no superar la unidad, se optó por un formato `quantized_bits(8, 0, 1)`, destinando 7 bits exclusivamente a la parte fraccionaria para maximizar la resolución matemática del acumulador.
- **Sesgo de Clasificación Final:** Se requirió de un bit entero mediante la configuración `quantized_bits(8, 1, 1)` para prevenir el desbordamiento de los valores continuos ligeramente mayores a 1.
- **Activaciones Internas (ReLU):** Se cuantizaron dinámicamente mediante `quantized_relu(8, 3)`, asumiendo que las activaciones internas pueden crecer.

2.3.3. Transferencia de Pesos y Entrenamiento Consciente de Cuantización (QAT)

Tras compilar el diccionario de cuantización, se instanció el nuevo modelo trasladando directamente los pesos previamente aprendidos en punto flotante (*Weight Transfer*). Debido a que la discretización abrupta de los valores induce un ruido de cuantización que degrada el *accuracy* inicial, el modelo fue sometido a una fase de calibración o Ajuste Fino (*Fine-Tuning*).

Este Entrenamiento Consciente de la Cuantización (*Quantization-Aware Training*) se ejecutó utilizando el optimizador Adam con una tasa de aprendizaje atenuada (10^{-3}). Esto permitió que la red adaptara suavemente sus parámetros a la nueva resolución de 8 bits.

2.3.4. Evaluación Comparativa de Rendimiento

El análisis de validación demostró la robustez intrínseca de la arquitectura propuesta frente a la reducción de precisión. Al evaluar las matrices de confusión para escenarios específicos, como una SNR de 8 dB, se constató que la topología de falsos positivos (por ejemplo, la clásica superposición entre WBFM y AM-DSB) se mantiene estructuralmente idéntica a la del modelo original en *Float32*.

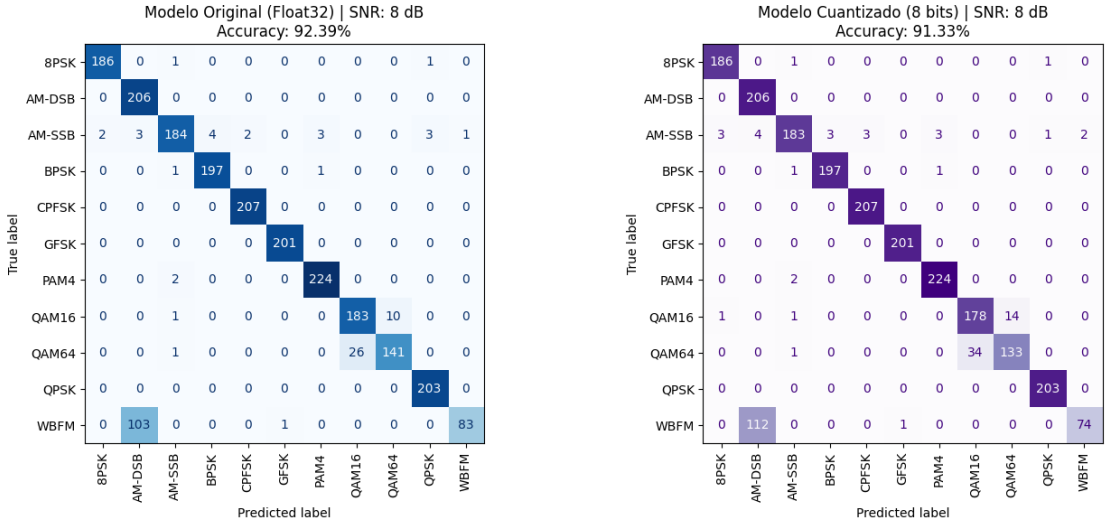

Figura 2.7: Matriz de Confusión para el modelo original y cuantizado.

Finalmente, la evaluación asintótica expresada en la curva de *Accuracy vs. SNR* verifica empíricamente el éxito del codiseño. La superposición casi perfecta entre el desempeño del modelo continuo y el modelo cuantizado evidencia que es factible reducir el costo computacional y el consumo energético sin penalizar la sensibilidad de la red neuronal.

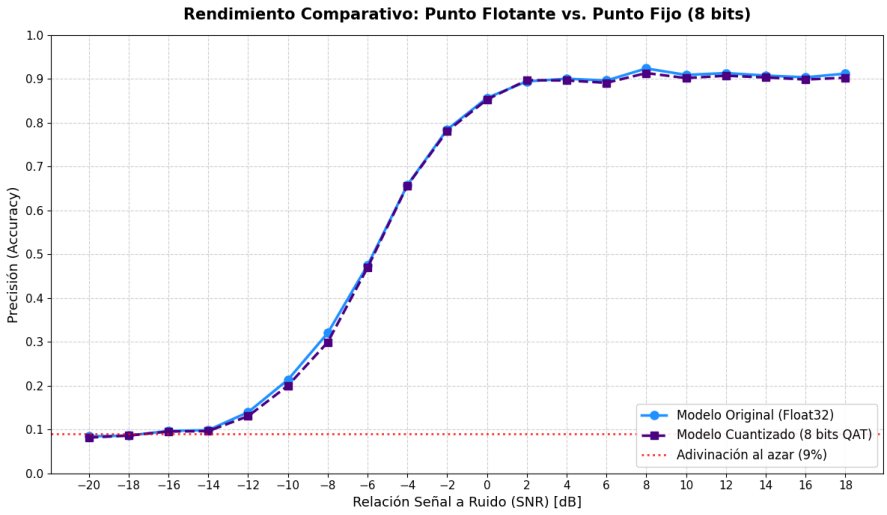

Figura 2.8: Curva de Precisión en función del SNR para el modelo original y cuantizado.

2.4. Análisis para Implementación en Hardware

2.4.1. Estimación Energética mediante QTools

Para validar la viabilidad física del modelo y cuantificar el impacto del codiseño hardware-software, se realizó una estimación del consumo energético de la fase de inferencia utilizando `QTools`. El análisis se basó en el modelo de energía del proceso de 45 nm propuesto por Horowitz (2014), el cual tabula el costo en picojulios (pJ) de las distintas operaciones aritméticas y accesos a memoria en función del ancho de bits.

Para modelar los bloques multiplicadores-acumuladores (MAC) físicos de manera realista, se estipuló el uso de acumuladores de 32 bits (`int32`). Esto resulta crítico en implementaciones VLSI, ya que la sumatoria iterativa de productos de 8 bits en registros estrechos provocaría desbordamientos aritméticos (*overflow*).

2.4.2. Perfilado de Operaciones y Huella de Memoria

La red requiere un total de $10,601,856$ operaciones MAC (multiplicaciones con signo de 8 bits, denotadas como `smult_8_8`) para procesar una ventana temporal completa de la señal I/Q.

En términos de almacenamiento, la consolidación de todos los pesos y sesgos cuantizados resulta en una huella de memoria estática de $1,006,168$ bits (aproximadamente 125,77 KB). Adicionalmente, el modelo presentó una escasez natural (*sparsity*) del 2,77 %.

2.4.3. Métricas Globales y Medida de Desempeño (Figure of Merit)

El consumo total estimado de la arquitectura ascendió a $2,999,833{,}0$ pJ (aproximadamente 3,0 μJ) por inferencia. Para contextualizar este gasto energético frente a la capacidad predictiva de la red, se definió una Medida de Desempeño o *Figure of Merit* (FoM). Esta métrica relaciona linealmente la precisión final del clasificador (*Accuracy*) con la energía invertida, expresándose en unidades de acierto por picojulio (Acc/pJ).

En la Tabla 1 se presenta un resumen de los resultados obtenidos:

Cuadro 1: Resumen de Hardware y Desempeño del Modelo ResNet-1D (8 bits)

Métrica de Hardware	**Valor Estimado**
Precisión (*Accuracy*)	0,5930
Operaciones MAC Totales	$10,601,856$
Huella de Memoria (*Weights + Biases*)	$1,006,168$ bits ($\sim$ 126 KB)
Índice de Escasez (*Sparsity*)	2,77 %
Energía Total por Inferencia	$2,999,833$,0 pJ ($\sim$ 3,0 μJ)
Medida de Desempeño (FoM)	$\mathbf{1{,}9768 \times 10^{-7}}$ Acc/pJ

2.5. Resultados y Discusión: Impacto de la Cuantización

Para consolidar el análisis del codiseño hardware-software, se llevó a cabo una evaluación comparativa sistemática entre tres iteraciones del modelo: la arquitectura original en punto flotante continuo (*Float32*), una versión cuantizada a 8 bits y una versión sometida a compresión extrema de 4 bits. Ambas versiones discretas fueron optimizadas mediante Entrenamiento Consciente de Cuantización (QAT) para garantizar una comparación justa. El impacto de la reducción del ancho de palabra (*bitwidth*) se analizó a través de tres ejes críticos: precisión algorítmica, huella de memoria y consumo energético.

2.5.1. Impacto sobre la Precisión (Accuracy vs. SNR)

La degradación del rendimiento se evaluó parametrizando la métrica de *accuracy* en función de la Relación Señal a Ruido (SNR) del canal de comunicaciones, barriendo el espectro desde -20 dB hasta $+18$ dB.

Como se observa en las curvas de rendimiento, la versión de 8 bits exhibe excelente comportamiento, superponiéndose de manera casi idéntica a la curva asintótica del modelo *Float32* (alcanzando precisiones cercanas al 80 % en alta SNR). Esto demuestra empíricamente que una resolución de 8 bits posee suficiente rango dinámico para capturar los patrones de fase y amplitud sin pérdida de información estructural.

En contraste, el modelo de 4 bits sufre una penalización evidente. A pesar de haber sido sometido a un proceso de calibración (QAT), la red satura prematuramente en la región de alto SNR. El impacto de la cuantización afecta principalmente a las modulaciones de orden superior (QAM16 y QAM64), que dependen de la precisión de los pesos para discriminar entre constelaciones densas.

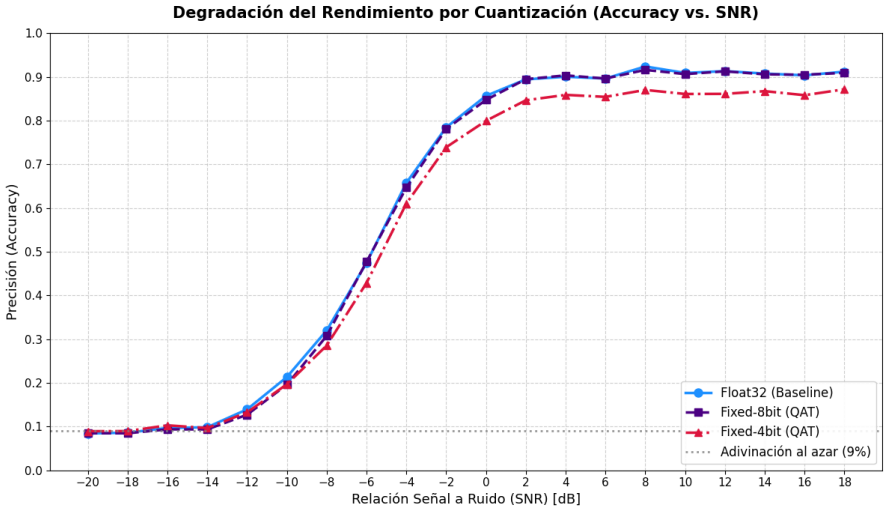

Figura 2.9: Curva de Precisión en función del SNR para el modelo original y ambas cuantizaciones (8 y 4 bits).

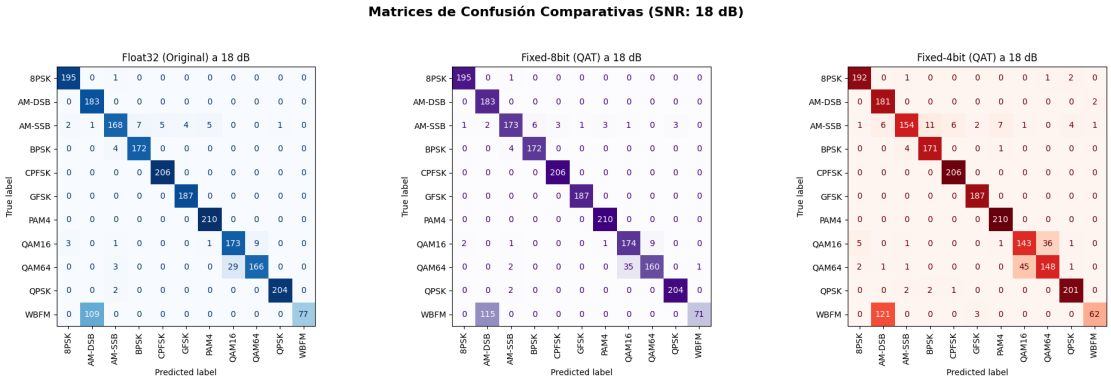

Figura 2.10: Matrices de Confusión Comparativas para el modelo original y ambas cuantizaciones (8 y 4 bits).

2.5.2. Impacto sobre la Estimación de Energía y Eficiencia

El costo energético de las operaciones de Multiplicación y Acumulación (MAC) decrece de forma cuadrática frente a la reducción del ancho de los operandos. Mientras que una inferencia en *Float32* requiere un consumo masivo debido a la complejidad de las unidades de coma flotante, la estimación mediante la herramienta `QTools` demostró que el modelo de 8 bits consume apenas $\sim 3{,}0\ \mu$J por clasificación.

Si bien el modelo de 4 bits reduciría aún más el consumo en los multiplicadores de hardware y en los buses de lectura de memoria, esta ganancia energética penaliza la tasa de clasificación. Por lo tanto, el análisis previo determina que el formato de **8 bits** es el punto de operación óptimo.